# **Book 2 (Accessing Text Corpora and Lexical Resources)**

SIDE-39-GAB

Bastomy - 1301178418 - Text Mining

# 1 Accessing Text Corpora

## 1.1 Gutenberg Corpus

```
In [1]:
        import nltk
         nltk.corpus.gutenberg.fileids()
Out[1]: ['austen-emma.txt',
          'austen-persuasion.txt',
          'austen-sense.txt',
          'bible-kjv.txt',
          'blake-poems.txt',
          'bryant-stories.txt',
          'burgess-busterbrown.txt',
          'carroll-alice.txt',
          'chesterton-ball.txt',
          'chesterton-brown.txt',
          'chesterton-thursday.txt',
          'edgeworth-parents.txt',
          'melville-moby dick.txt',
          'milton-paradise.txt',
          'shakespeare-caesar.txt',
          'shakespeare-hamlet.txt',
          'shakespeare-macbeth.txt',
          'whitman-leaves.txt']
```

contoh mengakses corpus kemudia menyimpannya dalam sebuah variabel

```
In [2]: emma = nltk.corpus.gutenberg.words('austen-emma.txt')
    persuasion = nltk.corpus.gutenberg.words('austen-persuasion.txt')
    sense = nltk.corpus.gutenberg.words('austen-sense.txt')
    poems = nltk.corpus.gutenberg.words('blake-poems.txt')
    stories = nltk.corpus.gutenberg.words('bryant-stories.txt')
```

contoh isi dari corpus yang telah di simpan dalam sebuah variabel

In [3]:

emma, persuasion, sense, poems, stories

```
Out[3]: (['[', 'Emma', 'by', 'Jane', 'Austen', '1816', ']', ...],
         ['[', 'Persuasion', 'by', 'Jane', 'Austen', '1818', ...],
         ['[', 'Sense', 'and', 'Sensibility', 'by', 'Jane', ...],
              , 'Poems', 'by', 'William', 'Blake', '1789', ']', ...],
         ['[', 'Stories', 'to', 'Tell', 'to', 'Children', 'by', ...])
        panjang dari setiap corpus yang tersedia
In [4]:
        print("Panjang corpus emma ",len(emma))
        print("Panjang corpus persuasion ",len(persuasion))
        print("Panjang corpus sense ",len(sense))
        print("Panjang corpus poems ",len(poems))
        print("Panjang corpus stories ",len(stories))
        Panjang corpus emma 192427
        Panjang corpus persuasion 98171
        Panjang corpus sense 141576
        Panjang corpus poems 8354
        Panjang corpus stories 55563
        detail dari setiap informasi mengetai text tersebut
In [5]:
        from nltk.corpus import gutenberg
In [6]:
         for fileid in gutenberg.fileids():
                 num chars = len(gutenberg.raw(fileid))
                 num words = len(gutenberg.words(fileid))
                 num sents = len(gutenberg.sents(fileid))
                 num vocab = len(set(w.lower() for w in gutenberg.words(fileid)))
                 print(round(num chars/num words), round(num words/num sents), round(num \( \)
        5 25 26 austen-emma.txt
        5 26 17 austen-persuasion.txt
        5 28 22 austen-sense.txt
        4 34 79 bible-kjv.txt
        5 19 5 blake-poems.txt
        4 19 14 bryant-stories.txt
        4 18 12 burgess-busterbrown.txt
        4 20 13 carroll-alice.txt
        5 20 12 chesterton-ball.txt
        5 23 11 chesterton-brown.txt
        5 18 11 chesterton-thursday.txt
        4 21 25 edgeworth-parents.txt
        5 26 15 melville-moby dick.txt
        5 52 11 milton-paradise.txt
        4 12 9 shakespeare-caesar.txt
        4 12 8 shakespeare-hamlet.txt
        4 12 7 shakespeare-macbeth.txt
        5 36 12 whitman-leaves.txt
```

cara mengakses mengakses text

```
In [7]: macbeth sentences = gutenberg.sents('shakespeare-macbeth.txt')
         emma = gutenberg.sents('austen-emma.txt')
 In [8]: macbeth sentences,emma
 Out[8]: ([['[', 'The', 'Tragedie', 'of', 'Macbeth', 'by', 'William', 'Shakespeare', '16
         03', ']'], ['Actus', 'Primus', '.'], ...],
          [['[', 'Emma', 'by', 'Jane', 'Austen', '1816', ']'], ['VOLUME', 'I'], ...])
         print("kalimat 1 pada macbeth_sentences ", macbeth_sentences[1])
 In [9]:
         print("kalimat 2 pada macbeth_sentences ", macbeth_sentences[2])
         print("kalimat 1 pada emma ", emma[1])
         print("kalimat 2 pada emma ", emma[2])
         kalimat 1 pada macbeth sentences ['Actus', 'Primus', '.']
         kalimat 2 pada macbeth sentences ['Scoena', 'Prima', '.']
         kalimat 1 pada emma ['VOLUME', 'I']
         kalimat 2 pada emma ['CHAPTER', 'I']
In [10]: longest len = max(len(s) for s in emma)
In [11]: | a= [s for s in emma if len(s) == longest len]
```

```
print(a)
```

[['While', 'he', 'lived', ',', 'it', 'must', 'be', 'only', 'an', 'engagement', ;', 'but', 'she', 'flattered', 'herself', ',', 'that', 'if', 'divested', 'of', 'the', 'danger', 'of', 'drawing', 'her', 'away', ',', 'it', 'might', 'become', 'an', 'increase', 'of', 'comfort', 'to', 'him', '.--', 'How', 'to', 'do', 'he r', 'best', 'by', 'Harriet', ',', 'was', 'of', 'more', 'difficult', 'decision', ';--', 'how', 'to', 'spare', 'her', 'from', 'any', 'unnecessary', 'pain', ';', 'how', 'to', 'make', 'her', 'any', 'possible', 'atonement', ';', 'how', 'to', 'appear', 'least', 'her', 'enemy', '?--', 'On', 'these', 'subjects', ',', 'he r', 'perplexity', 'and', 'distress', 'were', 'very', 'great', '--', 'and', 'he r', 'mind', 'had', 'to', 'pass', 'again', 'and', 'again', 'through', 'every', 'bitter', 'reproach', 'and', 'sorrowful', 'regret', 'that', 'had', 'ever', 'sur rounded', 'it', '.--', 'She', 'could', 'only', 'resolve', 'at', 'last', ',', 't hat', 'she', 'would', 'still', 'avoid', 'a', 'meeting', 'with', 'her', ', d', 'communicate', 'all', 'that', 'need', 'be', 'told', 'by', 'letter', hat', 'it', 'would', 'be', 'inexpressibly', 'desirable', 'to', 'have', 'her', 'removed', 'just', 'now', 'for', 'a', 'time', 'from', 'Highbury', ',', 'and', '--', 'indulging', 'in', 'one', 'scheme', 'more', '--', 'nearly', 'resolve', ',', 'that', 'it', 'might', 'be', 'practicable', 'to', 'get', 'an', 'invitatio n', 'for', 'her', 'to', 'Brunswick', 'Square', '.--', 'Isabella', 'had', 'bee n', 'pleased', 'with', 'Harriet', ';', 'and', 'a', 'few', 'weeks', 'spent', 'i
n', 'London', 'must', 'give', 'her', 'some', 'amusement', '.--', 'She', 'did',
'not', 'think', 'it', 'in', 'Harriet', "'", 's', 'nature', 'to', 'escape', 'bei
ng', 'benefited', 'by', 'novelty', 'and', 'variety', ',', 'by', 'the', 'street
s', ',', 'the', 'shops', ',', 'and', 'the', 'children', '.--', 'At', 'any', 'ra
te', ',', 'it', 'would', 'be', 'a', 'proof', 'of', 'attention', 'and', 'kindnes s', 'in', 'herself', ',', 'from', 'whom', 'every', 'thing', 'was', 'due', ';', 'a', 'separation', 'for', 'the', 'present', ';', 'an', 'averting', 'of', 'the', 'evil', 'day', ',', 'when', 'they', 'must', 'all', 'be', 'together', 'again', '.']]

```
In [12]: print("text terpanjang pada emma memiliki ",len(a[0])," kata")
```

text terpanjang pada emma memiliki 274 kata

#### 1.2 Web and Chat Text

```
In [13]: from nltk.corpus import webtext
In [14]: for fileid in webtext.fileids():
              print(fileid, webtext.raw(fileid)[:65], '...')
         firefox.txt Cookie Manager: "Don't allow sites that set removed cookies to se
         grail.txt SCENE 1: [wind] [clop clop clop]
         KING ARTHUR: Whoa there! [clop ...
         overheard.txt White guy: So, do you have any plans for this evening?
         Asian girl ...
         pirates.txt PIRATES OF THE CARRIBEAN: DEAD MAN'S CHEST, by Ted Elliott & Terr
         singles.txt 25 SEXY MALE, seeks attrac older single lady, for discreet encoun
         wine.txt Lovely delicate, fragrant Rhone wine. Polished leather and strawb ...
         menampilkan 10 chat room pertama dari file xml
In [15]: from nltk.corpus import nps chat
In [16]:
         chatroom = nps chat.posts('10-19-20s 706posts.xml')
         for i in range(len(chatroom)):
              if i< 10:
                  print(chatroom[i])
         ['now', 'im', 'left', 'with', 'this', 'gay', 'name']
         [':P']
         ['PART']
         ['hey', 'everyone']
         ['ah', 'well']
         ['NICK', ':', 'U7']
         ['U7', 'is', 'a', 'gay', 'name', '.']
         ['.', 'ACTION', 'gives', 'U121', 'a', 'golf', 'clap', '.']
         [':)']
         ['JOIN']
```

# 1.3 Brown Corpus

daftar dari brown corpus

ID	File	Genre	Description
A16	ca16	news	Chicago Tribune: Society Reportage
B02	cb02	editorial	Christian Science Monitor: Editorials
C17	cc17	reviews	Time Magazine: Reviews
D12	cd12	religion	Underwood: Probing the Ethics of Realtors
E36	ce36	hobbies	Norling: Renting a Car in Europe
F25	cf25	lore	Boroff: Jewish Teenage Culture
G22	cg22	belles_lettres	Reiner: Coping with Runaway Technology
H15	ch15	government	US Office of Civil and Defence Mobilization: The Family Fallout Shelter
J17	cj19	learned	Mosteller: Probability with Statistical Applications
K04	ck04	fiction	W.E.B. Du Bois: Worlds of Color
L13	cl13	mystery	Hitchens: Footsteps in the Night
M01	cm01	science_fiction	Heinlein: Stranger in a Strange Land
N14	cn15	adventure	Field: Rattlesnake Ridge
P12	cp12	romance	Callaghan: A Passion in Rome
R06	cr06	humor	Thurber: The Future, If Any, of Comedy

sebelum menggunakan brown corpus kita harus mengimport terlebih dahulu seperi code dibawah ini

```
In [17]: from nltk.corpus import brown
```

untuk mengecek ketersediaan kategori brown bisa dengan menggunakan code di bawah ini

```
In [18]:
          brown.categories()
Out[18]: ['adventure',
           'belles lettres',
           'editorial',
           'fiction',
           'government',
           'hobbies',
           'humor',
           'learned',
           'lore',
           'mystery',
           'news',
           'religion',
           'reviews',
           'romance',
           'science_fiction']
```

untuk menampilkan kategori tertentu bisa menggunakan code dibawah ini sesuai dengan kategori yang di inginkan

```
In [19]: print("humor ",brown.words(categories='humor'))
    print("hobbies ",brown.words(categories='hobbies'))
    print("editorial ",brown.words(categories='editorial'))
    print("mystery ",brown.words(categories='mystery'))

humor ['It', 'was', 'among', 'these', 'that', 'Hinkle', ...]
    hobbies ['Too', 'often', 'a', 'beginning', 'bodybuilder', ...]
    editorial ['Assembly', 'session', 'brought', 'much', 'good', ...]
    mystery ['There', 'were', 'thirty-eight', 'patients', 'on', ...]
```

untuk melihat beberapa kategori sekaligus kita dapat menggunakan kode dibawah ini

#### untuk melihat daftar field kita bisa menggunakan kode dibawah ini

```
In [21]: print(brown.fileids())
```

```
['ca01', 'ca02', 'ca03', 'ca04', 'ca05', 'ca06', 'ca07', 'ca08', 'ca09', 'ca1
0', 'ca11', 'ca12', 'ca13', 'ca14', 'ca15', 'ca16', 'ca17', 'ca18', 'ca19', 'ca
20', 'ca21', 'ca22', 'ca23', 'ca24', 'ca25', 'ca26', 'ca27', 'ca28', 'ca29', 'c a30', 'ca31', 'ca32', 'ca33', 'ca34', 'ca35', 'ca36', 'ca37', 'ca38', 'ca39',
'ca40', 'ca41', 'ca42', 'ca43', 'ca44', 'cb01', 'cb02', 'cb03', 'cb04', 'cb05',
         'cb07', 'cb08', 'cb09', 'cb10', 'cb11', 'cb12',
                                                             'cb13',
                                                                      'cb14',
        'cb17',
                'cb18', 'cb19',
                                  'cb20', 'cb21', 'cb22',
                                                             'cb23',
'cb16',
                                                                     'cb24',
        'cb27',
'cb26',
                                                             'cc06',
                 'cc01', 'cc02',
                                  'cc03', 'cc04', 'cc05',
                                                                      'cc07',
                                                                              'cc08'
                                                             'cc16',
         'cc10', 'cc11', 'cc12',
                                   'cc13',
                                           'cc14', 'cc15',
                                                                      'cc17',
                                                                              'cd01',
        'cd03', 'cd04', 'cd05', 'cd06', 'cd07', 'cd08', 'cd09',
                                                                     'cd10', 'cd11',
                                   'cd16',
                                           'cd17',
                                                    'ce01',
                                                             'ce02',
                 'cd14', 'cd15',
                                                                      'ce03',
         'cd13',
                                   'ce09',
                                          'ce10', 'ce11',
        'ce06', 'ce07', 'ce08',
                                                            'ce12',
                                                                     'ce13',
                                   'ce19',
                                                             'ce22',
                 'ce17', 'ce18',
                                           'ce20', 'ce21',
'ce15',
        'ce16',
                                                                      'ce23',
                                   'ce29',
                                           'ce30', 'ce31',
                                                                      'ce33',
        'ce26', 'ce27',
                        'ce28',
                                                            'ce32',
        'ce36', 'cf01', 'cf02',
                                  'cf03', 'cf04', 'cf05', 'cf06',
                                                                     'c<del>f</del>07',
         'cf10',
                                   'cf13',
'cf09',
                 'cf11',
                          'cf12',
                                           'cf14',
                                                    'cf15',
                                                             'cf16',
                                                                      'cf17'
        'cf20', 'cf21', 'cf22',
                                                             'cf26',
                                  'cf23', 'cf24', 'cf25',
                                                                     'cf27',
                                           'cf34',
                                                                      'cf37',
         'cf30',
                                   'cf33',
                                                             'cf36',
                 'cf31', 'cf32',
                                                    'cf35',
                                                                              'cf38',
        'cf40', 'cf41',
                         'cf42',
                                   'cf43',
                                           'cf44',
                                                   'cf45',
                                                             'cf46',
                                                                      'cf47',
                                                                              'cf48',
                                                                      'cg09',
         'cg02', 'cg03', 'cg04',
                                   'cg05', 'cg06', 'cg07',
                                                             'cg08',
'cg01',
                                                                              'cg10',
'cg11',
         'cg12',
                          'cg14',
                                   'cg15',
                                           'cg16',
                                                    'cg17',
                                                             'cg18',
                 'cg13',
                                                                      cg19',
                                                                              'cg20'
'cg21',
        'cg22',
                 'cg23',
                          'cg24',
                                   'cg25', 'cg26', 'cg27',
                                                             'cg28',
                                                                      'cg29',
                                                                              'cg30',
         'cg32',
                                   'cg35',
                                            'cg36', 'cg37',
                                                             'cg38',
                 'cg33',
                          'cg34',
                                                                      'cg39',
                                           'cg46', 'cg47',
        'cg42', 'cg43', 'cg44',
                                   'cg45',
                                                             'cg48',
                                                                      'cg49',
         'cg52',
                 'cg53',
                          'cg54',
                                   'cg55', 'cg56', 'cg57',
                                                             'cg58',
'cg51',
                                                                      'cg59',
                                                                              'cg60',
'cg61',
         'cg62',
                 'cg63',
                          'cg64',
                                   'cg65',
                                           'cg66',
                                                    'cg67',
                                                             'cg68',
                                                                      'cg69',
                                                                              'cg70',
'cg71',
        'cg72',
                                                             'ch03',
                          'cg74',
                                   'cg75', 'ch01', 'ch02',
                                                                              'ch05',
                 'cg73',
                                                                      'ch04',
         'ch07',
                 'ch08',
                                                             'ch13',
                                                                      'ch14',
                          'ch09',
                                           'ch11', 'ch12',
                                   'ch10',
                                                                              'ch15',
        'ch17', 'ch18', 'ch19', 'ch20', 'ch21', 'ch22', 'ch23',
                                                                     'ch24', 'ch25',
         'ch27',
                          'ch29',
                                   'ch30', 'cj01', 'cj02',
                                                             'cj03',
'ch26',
                 'ch28',
                                                                      'cj04',
                                                                              'cj05'
'cj06',
         'cj07',
                 'cj08',
                          'cj09',
                                   'cj10',
                                           'cj11',
                                                   'cj12',
                                                             'cj13',
                                                                      'cj14',
'cj16',
        'cj17',
                                                                      'cj24',
                 'cj18',
                          'cj19',
                                   'cj20', 'cj21', 'cj22',
                                                             'cj23',
                                                                              'cj25',
         'cj27',
                                   'cj30',
                                                             'cj33',
'cj26',
                 'cj28',
                          'cj29',
                                           'cj31', 'cj32',
                                                                      'cj34',
                                                                              'cj35'
        'cj37', 'cj38', 'cj39',
                                  'cj40', 'cj41', 'cj42',
                                                             'cj43',
                                                                      'cj44',
                                                                              'cj45',
                                   'cj50', 'cj51', 'cj52',
                                                             'cj53',
         'cj47',
                 'cj48',
                          'cj49',
                                                                      'cj54',
'cj46',
                                                                              'cj55'
         'cj57',
                 'cj58',
                                   'cj60',
                                           'cj61', 'cj62',
                                                             'cj63',
'ci56',
                          'cj59',
                                                                      'ci64',
                                                             'cj73',
         'cj67',
                                   'cj70',
'cj66',
                 'cj68',
                          'cj69',
                                           'cj71', 'cj72',
                                                                      'cj74',
                                                                              'cj75',
'cj76',
                 'cj78',
                                           'ck01', 'ck02',
                                                                      'ck04',
         'cj77',
                          'cj79',
                                   'cj80',
                                                             'ck03',
                                                                              'ck05',
                                                             'ck13',
        'ck07', 'ck08', 'ck09',
                                  'ck10', 'ck11', 'ck12',
                                                                      'ck14',
                                                                              'ck15',
                                   'ck20',
                          'ck19',
                                           'ck21',
                                                    'ck22',
                                                             'ck23',
                 'ck18',
                                                                      'ck24',
         'ck17',
        'ck27', 'ck28', 'ck29',
                                  'cl01', 'cl02', 'cl03',
                                                             'cl04',
                                                                     'cl05',
                 'cl09',
                                   'cl11',
                                                             'cl14',
         'cl08',
                          'cl10',
                                           'cl12', 'cl13',
                                                                      'cl15',
                                                                              'cl16',
                         'cl20',
                                   'cl21',
                                                   'cl23',
                                                             'cl24',
         'cl18',
                 'cl19',
                                           'cl22',
                                                                      'cm01',
                 'cm05', 'cm06',
                                  'cn01', 'cn02', 'cn03',
                                                             'cn04',
'cm03',
        'cm04',
                                                                      'cn05', 'cn06',
         'cn08',
                                   'cn11',
                                                             'cn14',
                                           'cn12',
                                                                      'cn15',
                 'cn09',
                          'cn10',
                                                    'cn13',
        'cn18', 'cn19', 'cn20',
                                  'cn21', 'cn22', 'cn23',
                                                             'cn24',
                                                                      'cn25',
                 'cn29',
                                   'cp02',
                                           'cp03', 'cp04',
                                                             'cp05',
         'cn28',
                          'cp01',
                                                                      'cp06',
                                           'cp13',
                                                   'cp14',
        'cp09', 'cp10', 'cp11',
                                   'cp12',
                                                             'cp15',
                                                                      'cp16',
                                  'cp22', 'cp23', 'cp24',
                                                            'cp25',
        'cp19', 'cp20', 'cp21',
                                                                     'cp26',
                                                                              'cp27'
        'cp29', 'cr01', 'cr02', 'cr03', 'cr04', 'cr05', 'cr06', 'cr07', 'cr08',
'cp28',
'cr09'l
```

untuk menampilkan field tertentu bisa menggunakan code dibawah ini sesuai dengan field yang di inginkan

```
In [22]: print("cg22 ",brown.words(fileids=['cg22']))
    print("cj77 ",brown.words(fileids=['cj77']))
    print("cr06 ",brown.words(fileids=['cr06']))
    print("cr09 ",brown.words(fileids=['cr09']))
    print("ck13 ",brown.words(fileids=['ck13']))

cg22 ['Does', 'our', 'society', 'have', 'a', 'runaway', ',', ...]
    cj77 ['Temperature', 'of', 'the', 'wash', 'and', 'rinse', ...]
    cr06 ['I', 'called', 'the', 'other', 'afternoon', 'on', ...]
    cr09 ['Dear', 'Sirs', ':', 'Let', 'me', 'begin', 'by', ...]
    ck13 ['In', 'the', 'dim', 'underwater', 'light', 'they', ...]
```

untuk melihat jumlah kemunculan kata dalam sebuah kategori kita dapat menggunakan kode di bawah ini

```
can could
                                may might
                                                   will
                                                            be
                                            must
                                                    389
            news
                    93
                           86
                                 66
                                        38
                                               50
                                                           526
       religion
                    82
                           59
                                 78
                                        12
                                               54
                                                     71
                                                           243
        hobbies
                           58
                                131
                                        22
                                               83
                                                    264
                                                           508
                   268
science_fiction
                           49
                                        12
                                                8
                                                     16
                                                            80
                    16
                                  4
         romance
                    74
                          193
                                  11
                                        51
                                               45
                                                     43
                                                           289
           humor
                    16
                           30
                                   8
                                         8
                                                9
                                                     13
                                                            78
```

# 1.4 Reuters Corpus

```
In [25]: from nltk.corpus import reuters
```

untuk melihat semua field dari reuters bisa menggunakan kode dibawah ini

```
In [26]: a = reuters.fileids()
```

```
In [27]: | for i in range(30):
              print(a[i])
         test/14826
         test/14828
         test/14829
         test/14832
         test/14833
         test/14839
         test/14840
         test/14841
         test/14842
         test/14843
         test/14844
         test/14849
         test/14852
         test/14854
         test/14858
         test/14859
         test/14860
         test/14861
         test/14862
         test/14863
         test/14865
         test/14867
         test/14872
         test/14873
         test/14875
         test/14876
         test/14877
         test/14881
         test/14882
         test/14885
```

untuk melihat semua categori dari reuters bisa menggunakan kode dibawah ini

reuters.categories() In [28]: Out[28]: ['acq', 'alum', 'barley', 'bop', 'carcass', 'castor-oil', 'cocoa', 'coconut', 'coconut-oil', 'coffee', 'copper', 'copra-cake', 'corn', 'cotton', 'cotton-oil', 'cpi', 'cpu', 'crude', 'df1', 'dlr', 'dmk', 'earn', 'fuel', 'gas', 'gnp', 'gold', 'grain', 'groundnut', 'groundnut-oil', 'heat', 'hog', 'housing', 'income', 'instal-debt', 'interest', 'ipi', 'iron-steel', 'jet', 'jobs', 'l-cattle', 'lead', 'lei', 'lin-oil', 'livestock', 'lumber', 'meal-feed', 'money-fx', 'money-supply', 'naphtha', 'nat-gas', 'nickel', 'nkr', 'nzdlr', 'oat',

```
'orange',
'palladium',
'palm-oil',
'palmkernel',
'pet-chem',
'platinum',
'potato',
'propane',
'rand',
'rape-oil',
'rapeseed',
'reserves',
'retail',
'rice',
'rubber',
'rye',
'ship',
'silver',
'sorghum',
'soy-meal',
'soy-oil',
'soybean',
'strategic-metal',
'sugar',
'sun-meal',
'sun-oil',
'sunseed',
'tea',
'tin',
'trade',
'veg-oil',
'wheat',
'wpi',
'yen',
'zinc']
```

untuk melihat training tertentu masuk ke dalam kategori yang mana bisa menggunakan kode di bawah ini

```
In [29]: print("training/9865 kategori = ",reuters.categories('training/9865'))
    print("test/14960 kategori = ",reuters.categories('test/14960'))
    print("training/10752 kategori = ",reuters.categories('training/10752'))
    print("training/11302 kategori = ",reuters.categories('training/11302'))
    print("training/11643 kategori = ",reuters.categories('training/11643'))

training/9865 kategori = ['barley', 'corn', 'grain', 'wheat']
    test/14960 kategori = ['earn']
    training/10752 kategori = ['coffee']
    training/11302 kategori = ['earn']
    training/11643 kategori = ['earn']
```

untuk melihat langsung beberapa training atau testing masuk ke kategori mana bisa menggunakan kode dibawah ini

```
In [30]: reuters.categories(['training/9865', 'training/9880','training/10752','training/
Out[30]: ['barley', 'coffee', 'corn', 'earn', 'grain', 'money-fx', 'wheat']
```

jika di balik kita ingin mengetahui training atau test mana saja yang termasuk ke dalam kategori tertentu

```
In [31]: reuters.fileids('rand')
Out[31]: ['test/21535', 'training/7043', 'training/9336']
```

jika di balik kita ingin mengetahui training atau test mana saja yang termasuk ke dalam beberapa kategori tertentu

```
reuters.fileids(['oat','rice'])
In [32]:
Out[32]: ['test/14832',
           'test/14858',
           'test/15206',
           'test/15367',
           'test/15567',
           'test/15871'
           'test/15875',
           'test/15906',
           'test/15928',
           'test/15952',
           'test/16071'
           'test/16079',
           'test/16099',
           'test/16147',
           'test/16601',
           'test/16784',
           'test/17962',
           'test/18609',
           'test/18642',
           'test/19059',
           'test/19165',
           'test/19275',
           'test/19388',
           'test/19668',
           'test/19835',
           'test/19947',
           'test/20052',
           'test/21570',
           'training/10519',
           'training/10830',
           'training/11216',
           'training/11536',
           'training/11640',
           'training/11655',
           'training/13123',
           'training/13129',
           'training/13294',
           'training/13852',
           'training/1405',
           'training/14515',
           'training/1590',
           'training/1882',
           'training/1915',
           'training/197',
           'training/228',
           'training/235',
           'training/3358'
           'training/3445',
           'training/4133',
           'training/417',
           'training/4314',
           'training/4549'
           'training/4678',
           'training/4719',
```

'training/5',

```
'training/5266',
'training/5610',
'training/6114',
'training/6153',
'training/6269',
'training/7160',
'training/7545',
'training/7917',
'training/8161',
'training/8413',
'training/855',
'training/8759',
'training/97018',
'training/9705']
```

menampilkan 10 kata pertama pada data training atau test tertentu bisa menggunakan kode dibawah ini

jika ingin langsung dari beberapa data bisa menggunakan kode dibawah ini

```
In [34]: reuters.words(['training/9865', 'training/9880','training/12067'])
Out[34]: ['FRENCH', 'FREE', 'MARKET', 'CEREAL', 'EXPORT', ...]
```

jika ingin mencari kata yang terdapat dalam suatu kategori dapat menggunakan kode dibawah ini

```
In [35]: reuters.words(categories='tea')
Out[35]: ['PAKISTAN', 'CONFIRMS', 'KENYA', 'TEA', 'IMPORT', ...]
```

jika ingin mencari kata yang terdapat dalam beberapa kategori dapat menggunakan kode dibawah ini

```
In [36]: reuters.words(categories=['barley', 'rice'])
Out[36]: ['THAI', 'TRADE', 'DEFICIT', 'WIDENS', 'IN', 'FIRST', ...]
```

# 1.5 Inaugural Address Corpus

In [37]: from nltk.corpus import inaugural

field yang tersedia pada inagural corpus

In [38]: inaugural.fileids() Out[38]: ['1789-Washington.txt', '1793-Washington.txt', '1797-Adams.txt', '1801-Jefferson.txt', '1805-Jefferson.txt', '1809-Madison.txt', '1813-Madison.txt', '1817-Monroe.txt', '1821-Monroe.txt', '1825-Adams.txt', '1829-Jackson.txt', '1833-Jackson.txt', '1837-VanBuren.txt', '1841-Harrison.txt', '1845-Polk.txt', '1849-Taylor.txt', '1853-Pierce.txt', '1857-Buchanan.txt', '1861-Lincoln.txt', '1865-Lincoln.txt', '1869-Grant.txt', '1873-Grant.txt', '1877-Hayes.txt', '1881-Garfield.txt', '1885-Cleveland.txt', '1889-Harrison.txt', '1893-Cleveland.txt', '1897-McKinley.txt', '1901-McKinley.txt', '1905-Roosevelt.txt', '1909-Taft.txt', '1913-Wilson.txt', '1917-Wilson.txt', '1921-Harding.txt', '1925-Coolidge.txt', '1929-Hoover.txt', '1933-Roosevelt.txt' '1937-Roosevelt.txt', '1941-Roosevelt.txt', '1945-Roosevelt.txt', '1949-Truman.txt', '1953-Eisenhower.txt', '1957-Eisenhower.txt', '1961-Kennedy.txt', '1965-Johnson.txt', '1969-Nixon.txt', '1973-Nixon.txt', '1977-Carter.txt', '1981-Reagan.txt', '1985-Reagan.txt', '1989-Bush.txt', '1993-Clinton.txt', '1997-Clinton.txt', '2001-Bush.txt',

```
'2005-Bush.txt',
'2009-Obama.txt']
```

untuk membuat sebuah plot dari kemunculan kata tertentu pada beberapa tahun tertentu dapat menggunakan kode dibawah ini

```
In [39]: cfd = nltk.ConditionalFreqDist(
          (target, fileid[:4])
          for fileid in inaugural.fileids()
          for w in inaugural.words(fileid)
          for target in ['america', 'citizen', 'people']
          if w.lower().startswith(target))
```

```
In [40]: cfd.plot()
```

<Figure size 640x480 with 1 Axes>

## 1.6 Annotated Text Corpora

beberapa corpus yang tersedia

Corpus Compiler Contents Brown Corpus Francis, Kucera 15 genres, 1.15M words, tagged, categorized CESS Treebanks CLiC-UB 1M words, tagged and parsed (Catalan, Spanish) Chat-80 Data Files Pereira & Warren World Geographic Database 127k entries CMU Pronouncing Dictionary CMU CoNLL 2000 Chunking Data CoNLL 270k words, tagged and chunked CoNLL 2002 Named Entity CoNLL 700k words, pos- and named-entity-tagged (Dutch, Spanish) CoNLL 2007 Dependency Treebanks (sel) CoNLL 150k words, dependency parsed (Basque, Catalan) Dependency Treebank Narad Dependency parsed version of Penn Treebank sample FrameNet Fillmore, Baker et al 10k word senses, 170k manually annotated sentences Floresta Treebank Diana Santos et al 9k sentences, tagged and parsed (Portuguese) Lists of cities and countries Gazetteer Lists Various Genesis Corpus Misc web sources 6 texts, 200k words, 6 languages 18 texts, 2M words Gutenberg (selections) Hart, Newby, et al Inaugural Address Corpus CSpan US Presidential Inaugural Addresses (1789-present) Indian POS-Tagged Corpus Kumaran et al 60k words, tagged (Bangla, Hindi, Marathi, Telugu) NILC, USP, Brazil 1M words, tagged (Brazilian Portuguese) MacMorpho Corpus Movie Reviews Pang, Lee 2k movie reviews with sentiment polarity classification Names Corpus Kantrowitz, Ross 8k male and female names NIST 1999 Info Extr (selections) Garofolo 63k words, newswire and named-entity SGML markup 115k propositions, 1400 noun frames Nombank Meyers Forsyth, Martell NPS Chat Corpus 10k IM chat posts, POS-tagged and dialogue-act tagged Open Multilingual WordNet Bond et al 15 languages, aligned to English WordNet 28k prepositional phrases, tagged as noun or verb modifiers PP Attachment Corpus Ratnaparkhi Proposition Bank Palmer 113k propositions, 3300 verb frames Question Classification Li. Roth 6k questions, categorized Reuters Corpus Reuters 1.3M words, 10k news documents, categorized Roget's Thesaurus Project Gutenberg 200k words, formatted text RTE Textual Entailment 8k sentence pairs, categorized Dagan et al Rus, Mihalcea 880k words, part-of-speech and sense tagged SEMCOR Senseval 2 Corpus Pedersen 600k words, part-of-speech and sense tagged sentiment scores for 145k WordNet synonym sets SentiWordNet Esuli, Sebastiani 8 books in XML format Shakespeare texts (selections) Bosak State of the Union Corpus CSPAN 485k words, formatted text Stopwords Corpus Porter et al 2,400 stopwords for 11 languages Wiktionary Swadesh Corpus comparative wordlists in 24 languages Switchboard Corpus (selections) LDC 36 phonecalls, transcribed, parsed United Nations Univ Decl of Human Rights 480k words, 300+ languages Penn Treebank (selections) LDC 40k words, tagged and parsed TIMIT Corpus (selections) NIST/LDC audio files and transcripts for 16 speakers 5k verbs, hierarchically organized, linked to WordNet VerbNet 2.1 Palmer et al Wordlist Corpus OpenOffice.org et al 960k words and 20k affixes for 8 languages WordNet 3.0 (English) Miller, Fellbaum 145k synonym sets

# 1.7 Corpora in Other Languages

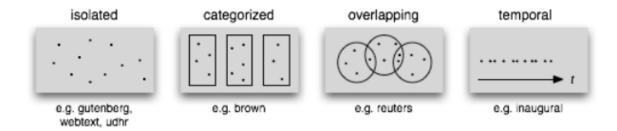
untuk menggunakan corpus di bahasa lain kita bisa menggunakan kode dibawah ini

```
In [41]:
          import nltk
          nltk.download('cess esp')
          nltk.download('floresta')
          nltk.download('indian')
          nltk.download('udhr')
          [nltk_data] Downloading package cess_esp to
          [nltk_data]
                           C:\Users\Bastomy\AppData\Roaming\nltk data...
                         Package cess esp is already up-to-date!
          [nltk data]
          [nltk data] Downloading package floresta to
          [nltk_data]
                           C:\Users\Bastomy\AppData\Roaming\nltk_data...
          [nltk data]
                         Package floresta is already up-to-date!
          [nltk data] Downloading package indian to
          [nltk data]
                           C:\Users\Bastomy\AppData\Roaming\nltk data...
          [nltk data]
                         Package indian is already up-to-date!
          [nltk data] Downloading package udhr to
          [nltk data]
                           C:\Users\Bastomy\AppData\Roaming\nltk_data...
          [nltk_data]
                         Package udhr is already up-to-date!
Out[41]: True
          print("Spanyol ",nltk.corpus.cess_esp.words())
In [42]:
          print("Floresta ",nltk.corpus.floresta.words())
          print("Indian ",nltk.corpus.indian.words('hindi.pos'))
          Spanyol ['El', 'grupo', 'estatal', 'Electricité de France', ...]
          Floresta ['Um', 'revivalismo', 'refrescante', '0', '7_e_Meio', ...]
Indian ['पूर्ण', 'प्रतिबंध', 'हटाओ', ':', 'इराक', 'संयुक्त', ...]
In [43]:
          from nltk.corpus import udhr
          languages = ['Chickasaw', 'English', 'German_Deutsch', 'Greenlandic_Inuktikut',
In [44]: | cfd = nltk.ConditionalFreqDist(
              (lang, len(word))
              for lang in languages
              for word in udhr.words(lang + '-Latin1'))
In [45]: cfd.plot(cumulative=True)
             2000
             1750
           Cumulative Counts
             1500
             1250
             1000
                                                Chickasaw
                                                English
              750
                                                German Deutsch
              500
                                                Greenlandic Inuktikut
                                                Hungarian Magyar
              250
                                                Ibibio Efik
```

Samples

## 1.8 Text Corpus Structure

berikut beberapa struktur dari corpus yang dimiliki NLTK



fungsi dasar dari nltk corpus

```
Example
                                                    Description
fileids()
                               the files of the corpus
fileids([categories])
                               the files of the corpus corresponding to these
                               categories
categories()
                               the categories of the corpus
categories([fileids])
                               the categories of the corpus corresponding to these
                               files
                               the raw content of the corpus
raw(fileids=[f1,f2,f3])
                               the raw content of the specified files
raw(categories=[c1,c2])
                               the raw content of the specified categories
                               the words of the whole corpus
words(fileids=[f1,f2,f3])
                               the words of the specified fileids
words(categories=[c1,c2])
                               the words of the specified categories
                               the sentences of the whole corpus
sents()
sents(fileids=[f1,f2,f3])
                               the sentences of the specified fileids
sents(categories=[c1,c2])
                               the sentences of the specified categories
abspath(fileid)
                               the location of the given file on disk
encoding(fileid)
                               the encoding of the file (if known)
open(fileid)
                               open a stream for reading the given corpus file
                               if the path to the root of locally installed corpus
root
readme()
                               the contents of the README file of the corpus
```

# 1.9 Loading your own Corpus

untuk membaca corpus sendiri kita dapat menggunakan kode dibawah ini

```
In [47]: wordlists.fileids()
Out[47]: ['malin_kundang.txt']
```

# 2 Conditional Frequency Distributions

#### 2.1 Conditions and Events

```
In [48]: text = ['The', 'Fulton', 'County', 'Grand', 'Jury', 'said', ...]
pairs = [('news', 'The'), ('news', 'Fulton'), ('news', 'County'), ...]
```

## 2.2 Counting Words by Genre

```
In [49]: import nltk
         from nltk.corpus import brown
         cfd = nltk.ConditionalFreqDist(
                     (genre, word)
                     for genre in brown.categories()
                     for word in brown.words(categories=genre))
In [50]: | genre_word = [(genre, word)
                        for genre in ['news', 'romance']
                        for word in brown.words(categories=genre)]
         len(genre_word)
Out[50]: 170576
In [51]: | genre_word[:4]
Out[51]: [('news', 'The'), ('news', 'Fulton'), ('news', 'County'), ('news', 'Grand')]
In [52]: | genre_word[-4:]
('romance', '.')]
In [53]: | cfd = nltk.ConditionalFreqDist(genre word)
In [54]: cfd
Out[54]: <ConditionalFreqDist with 2 conditions>
In [55]: cfd.conditions()
Out[55]: ['news', 'romance']
```

```
In [56]: print(cfd['news'])
          <FreqDist with 14394 samples and 100554 outcomes>
In [57]: print(cfd['romance'])
          <FreqDist with 8452 samples and 70022 outcomes>
In [58]: cfd['romance'].most common(20)
Out[58]: [(',', 3899),
           ('.', 3736),
           ('the', 2758),
           ('and', 1776),
           ('to', 1502),
           ('a', 1335),
           ('of', 1186),
           ('``', 1045),
("''", 1044),
           ('was', 993),
           ('I', 951),
           ('in', 875),
           ('he', 702),
           ('had', 692),
           ('?', 690),
           ('her', 651),
           ('that', 583),
           ('it', 573),
           ('his', 559),
           ('she', 496)]
In [59]: cfd['romance']['could']
Out[59]: 193
```

```
2.3 Plotting and Tabulating Distributions
In [60]:
         from nltk.corpus import inaugural
         cfd = nltk.ConditionalFreqDist(
                   (target, fileid[:4])
                   for fileid in inaugural.fileids()
                   for w in inaugural.words(fileid)
                   for target in ['america', 'citizen']
                   if w.lower().startswith(target))
In [61]: from nltk.corpus import udhr
         languages = ['Chickasaw', 'English', 'German_Deutsch',
              'Greenlandic_Inuktikut', 'Hungarian_Magyar', 'Ibibio_Efik']
         cfd = nltk.ConditionalFreqDist(
                   (lang, len(word))
                   for lang in languages
                   for word in udhr.words(lang + '-Latin1'))
```

## 2.4 Generating Random Text with Bigrams

```
In [63]: sent = ['In', 'the', 'beginning', 'God', 'created', 'the', 'heaven', 'and', 'the'
In [64]: list(nltk.bigrams(sent))
Out[64]: [('In', 'the'),
          ('the', 'beginning'),
          ('beginning', 'God'),
          ('God', 'created'),
           ('created', 'the'),
           ('the', 'heaven'),
           ('heaven', 'and'),
          ('and', 'the'),
           ('the', 'earth'),
          ('earth', '.')]
In [65]: def generate model(cfdist, word, num=15):
             for i in range(num):
                  print(word, end=' ')
                 word = cfdist[word].max()
         text = nltk.corpus.genesis.words('english-kjv.txt')
         bigrams = nltk.bigrams(text)
         cfd = nltk.ConditionalFreqDist(bigrams)
In [66]: cfd['living']
Out[66]: FreqDist({'creature': 7, 'thing': 4, 'substance': 2, 'soul': 1, '.': 1, ',':
         generate model(cfd, 'living')
In [67]:
         living creature that he said , and the land of the land of the land
```

# 3 More Python: Reusing Code

# 3.1 Creating Programs with a Text Editor

### 3.2 Functions

function sangat berguna jika kita menggunakan fungsi yang digunakan berulang-ulang, hal ini akan berguna agar kita tidak menulis kode program yang sama secara berulang

```
In [69]:
         import math
In [70]: def faktorial(x):
             print('faktorial dari ',x,' adalah ', math.factorial(x))
In [71]:
         faktorial(1)
         faktorial(2)
         faktorial(3)
         faktorial(4)
         faktorial(5)
         faktorial dari 1 adalah 1
         faktorial dari 2 adalah 2
         faktorial dari 3 adalah 6
         faktorial dari 4 adalah
                                   24
         faktorial dari 5 adalah
                                   120
```

di atas adalah contoh dari fungsi membuat faktorial, kita hanya tinggal memanggil fungsi yang sudah dibuat dan memasukan parameter yang dibutuhkan

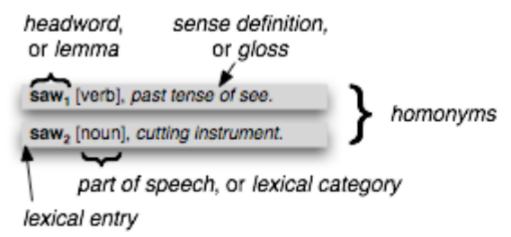
### 3.3 Modules

module adalah mengimport dari file python lain untuk digunakan fungsinya

contoh jika fungsi faktorial diatas d save dalam sebuah file bernama perhitungan maka cara memanggil modulnya adalah

```
import perhitungan perhitungan.faktorial(1)
```

# **4 Lexical Resources**



## 4.1 Wordlist Corpora

dalam nltk terdapat list dari stopword atau kata yang tidak penting, untuk memanggil wordlist tersebut kita harus mengimport stopwords seperti pada code dibawah ini

```
In [72]: from nltk.corpus import stopwords
```

berikut adalah daftar stopword bahasa inggris

```
In [73]:
           stopwords.words('english')
Out[73]: ['i',
            'me',
            'my',
            'myself',
            'we',
            'our',
            'ours',
            'ourselves',
            'you',
            "you're",
            "you've",
            "you'll",
            "you'd",
            'your',
            'yours',
            'yourself',
            'yourselves',
            'he',
            'him',
            11.2.1
```

Untuk bahasa indonesia bisa menggunakan code seperti dibawah ini

In [74]: print(stopwords.words('indonesian'))

['ada', 'adalah', 'adanya', 'adapun', 'agak', 'agaknya', 'agar', 'akan', 'akank ah', 'akhir', 'akhiri', 'akhirnya', 'aku', 'akulah', 'amat', 'amatlah', 'anda', 'andalah', 'antar', 'antara', 'antaranya', 'apa', 'apaan', 'apabila', 'apakah', 'apalagi', 'apatah', 'artinya', 'asal', 'asalkan', 'atas', 'atau', 'ataukah', 'ataupun', 'awal', 'awalnya', 'bagai', 'bagaikan', 'bagaimana', 'bagaimanakah', 'bagaimanapun', 'bagi', 'bagian', 'bahkan', 'bahwa', 'bahwasanya', 'baik', 'bak al', 'bakalan', 'balik', 'banyak', 'bapak', 'baru', 'bawah', 'beberapa', 'begin i', 'beginian', 'beginikah', 'beginilah', 'begitu', 'begitukah', 'begitulah', 'begitupun', 'bekerja', 'belakang', 'belakangan', 'belum', 'belumlah', 'benar', 'benarkah', 'benarlah', 'berada', 'berakhir', 'berakhirlah', 'berakhirnya', 'be rapa', 'berapakah', 'berapalah', 'berapapun', 'berarti', 'berawal', 'berbagai', 'berdatangan', 'beri', 'berikan', 'berikut', 'berikutnya', 'berjumlah', 'berkal i-kali', 'berkata', 'berkehendak', 'berkeinginan', 'berkenaan', 'berlainan', 'b erlalu', 'berlangsung', 'berlebihan', 'bermacam', 'bermacam-macam', 'bermaksu d', 'bermula', 'bersama', 'bersama-sama', 'bersiap', 'bersiap-siap', 'bertany a', 'bertanya-tanya', 'berturut', 'berturut-turut', 'bertutur', 'berujar', 'ber upa', 'besar', 'betul', 'betulkah', 'biasa', 'biasanya', 'bila', 'bilakah', 'bi sa', 'bisakah', 'boleh', 'bolehkah', 'bolehlah', 'buat', 'bukan', 'bukankah', 'bukanlah', 'bukannya', 'bulan', 'bung', 'cara', 'caranya', 'cukupka h', 'cukuplah', 'cuma', 'dahulu', 'dalam', 'dan', 'dapat', 'dari', 'daripada', 'datang', 'dekat', 'demi', 'demikian', 'demikianlah', 'dengan', 'depan', 'di', 'dia', 'diakhiri', 'diakhirinya', 'dialah', 'diantara', 'diantaranya', 'diber i', 'diberikan', 'diberikannya', 'dibuat', 'dibuatnya', 'didapat', 'didatangka n', 'digunakan', 'diibaratkan', 'diibaratkannya', 'diingat', 'diingatkan', 'dii nginkan', 'dijawab', 'dijelaskan', 'dijelaskannya', 'dikarenakan', 'dikatakan', 'dikatakannya', 'dikerjakan', 'diketahui', 'diketahuinya', 'dikira', 'dilakuka n', 'dilalui', 'dilihat', 'dimaksud', 'dimaksudkan', 'dimaksudkannya', 'dimaksu dnya', 'diminta', 'dimintai', 'dimisalkan', 'dimulai', 'dimulailah', 'dimulainy a', 'dimungkinkan', 'dini', 'dipastikan', 'diperbuat', 'diperbuatnya', 'dipergu nakan', 'diperkirakan', 'diperlihatkan', 'diperlukan', 'diperlukannya', 'dipers oalkan', 'dipertanyakan', 'dipunyai', 'diri', 'dirinya', 'disampaikan', 'disebu t', 'disebutkan', 'disebutkannya', 'disini', 'disinilah', 'ditambahkan', 'ditan daskan', 'ditanya', 'ditanyakan', 'ditegaskan', 'ditujukan', 'ditun juk', 'ditunjuki', 'ditunjukkan', 'ditunjukkannya', 'ditunjuknya', 'dituturka n', 'dituturkannya', 'diucapkan', 'diucapkannya', 'diungkapkan', 'dong', 'dua', 'dulu', 'empat', 'enggak', 'enggaknya', 'entah', 'entahlah', 'guna', 'gunakan', 'hal', 'hampir', 'hanya', 'hanyalah', 'hari', 'harus', 'haruslah', 'harusnya', 'hendak', 'hendaklah', 'hendaknya', 'hingga', 'ia', 'ialah', 'ibarat', 'ibaratk an', 'ibaratnya', 'ibu', 'ikut', 'ingat', 'ingat-ingat', 'ingin', 'inginkah', 'inginkan', 'ini', 'inikah', 'inilah', 'itu', 'itukah', 'itulah', 'jadi', 'jadi lah', 'jadinya', 'jangan', 'jangankan', 'janganlah', 'jauh', 'jawab', 'jawaba n', 'jawabnya', 'jelas', 'jelaskan', 'jelaslah', 'jelasnya', 'jika', 'jikalau', 'juga', 'jumlah', 'jumlahnya', 'justru', 'kala', 'kalau', 'kalaulah', 'kalaupu n', 'kalian', 'kami', 'kamilah', 'kamu', 'kamulah', 'kan', 'kapan', 'kapankah', 'kapanpun', 'karena', 'karenanya', 'kasus', 'kata', 'katakan', 'katakanlah', 'k atanya', 'ke', 'keadaan', 'kebetulan', 'kecil', 'kedua', 'keduanya', 'keingina n', 'kelamaan', 'kelihatan', 'kelihatannya', 'kelima', 'keluar', 'kembali', 'ke mudian', 'kemungkinan', 'kemungkinannya', 'kenapa', 'kepada', 'kepadanya', 'kes ampaian', 'keseluruhan', 'keseluruhannya', 'keterlaluan', 'ketika', 'khususny a', 'kini', 'kinilah', 'kira', 'kira-kira', 'kiranya', 'kita', 'kitalah', 'ko k', 'kurang', 'lagi', 'lagian', 'lah', 'lain', 'lainnya', 'lalu', 'lama', 'lama nya', 'lanjut', 'lanjutnya', 'lebih', 'lewat', 'lima', 'luar', 'macam', 'maka', 'makanya', 'makin', 'malah', 'malahan', 'mampu', 'mampukah', 'mana', 'manakal a', 'manalagi', 'masa', 'masalah', 'masalahnya', 'masih', 'masihkah', 'masing', 'masing-masing', 'mau', 'maupun', 'melainkan', 'melakukan', 'melalui', 'meliha

t', 'melihatnya', 'memang', 'memastikan', 'memberi', 'memberikan', 'membuat', 'memerlukan', 'memihak', 'meminta', 'memintakan', 'memisalkan', 'memperbuat', 'mempergunakan', 'memperkirakan', 'memperlihatkan', 'mempersiapkan', 'mempersoa lkan', 'mempertanyakan', 'mempunyai', 'memulai', 'memungkinkan', 'menaiki', 'me nambahkan', 'menandaskan', 'menanti', 'menanti-nanti', 'menantikan', 'menanya', 'menanyai', 'menanyakan', 'mendapat', 'mendapatkan', 'mendatangi', 'mendatangkan', 'menegaskan', 'mengakhiri', 'mengapa', 'mengatakan', 'mengataka nnya', 'mengenai', 'mengerjakan', 'mengetahui', 'menggunakan', 'menghendaki', 'mengibaratkan', 'mengibaratkannya', 'mengingat', 'mengingatkan', 'menginginka n', 'mengira', 'mengucapkan', 'mengucapkannya', 'mengungkapkan', 'menjadi', 'me njawab', 'menjelaskan', 'menuju', 'menunjuk', 'menunjuki', 'menunjukkan', 'menu njuknya', 'menurut', 'menuturkan', 'menyampaikan', 'menyangkut', 'menyatakan', 'menyebutkan', 'menyeluruh', 'menyiapkan', 'merasa', 'mereka', 'merekalah', 'me rupakan', 'meski', 'meskipun', 'meyakini', 'meyakinkan', 'minta', 'mirip', 'mis al', 'misalkan', 'misalnya', 'mula', 'mulai', 'mulailah', 'mulanya', 'mungkin', 'mungkinkah', 'nah', 'naik', 'namun', 'nanti', 'nantinya', 'nyaris', 'nyatany a', 'oleh', 'olehnya', 'pada', 'padahal', 'padanya', 'pak', 'paling', 'panjan g', 'pantas', 'para', 'pasti', 'pastilah', 'penting', 'pentingnya', 'per', 'per cuma', 'perlu', 'perlukah', 'perlunya', 'pernah', 'persoalan', 'pertama', 'pertama-tama', 'pertanyaan', 'pertanyakan', 'pihak', 'pihaknya', 'pukul', 'pula', 'pun', 'punya', 'rasa', 'rasanya', 'rata', 'rupanya', 'saat', 'saatnya', 'saj a', 'sajalah', 'saling', 'sama', 'sama-sama', 'sambil', 'sampai', 'sampai-sampa i', 'sampaikan', 'sana', 'sangat', 'sangatlah', 'satu', 'saya', 'sayalah', 's e', 'sebab', 'sebagai', 'sebagaimana', 'sebagainya', 'sebagian', 's ebaik', 'sebaik-baiknya', 'sebaiknya', 'sebaliknya', 'sebanyak', 'sebegini', 's ebegitu', 'sebelum', 'sebelumnya', 'sebenarnya', 'seberapa', 'sebesar', 'sebetu lnya', 'sebisanya', 'sebuah', 'sebut', 'sebutlah', 'sebutnya', 'secara', 'secuk upnya', 'sedang', 'sedangkan', 'sedemikian', 'sedikit', 'sedikitnya', 'seenakny a', 'segala', 'segalanya', 'segera', 'seharusnya', 'sehingga', 'seingat', 'seja k', 'sejauh', 'sejenak', 'sejumlah', 'sekadar', 'sekadarnya', 'sekali', 'sekali -kali', 'sekalian', 'sekaligus', 'sekalipun', 'sekarang', 'sekarang', 'sekeci l', 'seketika', 'sekiranya', 'sekitar', 'sekitarnya', 'sekurang-kurangnya', 'se kurangnya', 'selain', 'selaku', 'selalu', 'selama-lamanya', 'selamanya', 'selanjutnya', 'seluruh', 'seluruhnya', 'semacam', 'semakin', 'sem ampu', 'semampunya', 'semasa', 'semasih', 'semata', 'semata-mata', 'semaunya', 'sementara', 'semisal', 'semisalnya', 'sempat', 'semua', 'semuanya', 'semula', 'sendiri', 'sendirian', 'sendirinya', 'seolah', 'seolah-olah', 'seorang', 'sepa njang', 'sepantasnya', 'sepantasnyalah', 'seperlunya', 'seperti', 'sepertinya', 'sepihak', 'sering', 'seringnya', 'serta', 'serupa', 'sesaat', 'sesama', 'sesam pai', 'sesegera', 'sesekali', 'seseorang', 'sesuatu', 'sesuatunya', 'sesudah', 'sesudahnya', 'setelah', 'setempat', 'setengah', 'seterusnya', 'setiap', 'setib a', 'setibanya', 'setidak-tidaknya', 'setidaknya', 'setinggi', 'seusai', 'sewak tu', 'siap', 'siapakah', 'siapapun', 'sini', 'sinilah', 'soal', 'soaln ya', 'suatu', 'sudah', 'sudahkah', 'sudahlah', 'supaya', 'tadi', 'tadinya', 'ta hu', 'tahun', 'tak', 'tambah', 'tambahnya', 'tampak', 'tampaknya', 'tandas', 't andasnya', 'tanpa', 'tanya', 'tanyakan', 'tanyanya', 'tapi', 'tegas', 'tegasny a', 'telah', 'tempat', 'tengah', 'tentang', 'tentu', 'tentulah', 'tentunya', 't epat', 'terakhir', 'terasa', 'terbanyak', 'terdahulu', 'terdapat', 'terdiri', 'terhadap', 'terhadapnya', 'teringat', 'teringat-ingat', 'terjadi', 'terjadila h', 'terjadinya', 'terkira', 'terlalu', 'terlebih', 'terlihat', 'termasuk', 'ternyata', 'tersampaikan', 'tersebut', 'tersebutlah', 'tertentu', 'tertuju', 'ter us', 'terutama', 'tetap', 'tetapi', 'tiap', 'tiba', 'tiba-tiba', 'tidak', 'tida kkah', 'tidaklah', 'tiga', 'tinggi', 'toh', 'tunjuk', 'turut', 'tutur', 'tuturn ya', 'ucap', 'ucapnya', 'ujar', 'ujarnya', 'umum', 'umumnya', 'ungkap', 'ungkap nya', 'untuk', 'usah', 'usai', 'waduh', 'wahai', 'waktu', 'waktunya', 'w alau', 'walaupun', 'wong', 'yaitu', 'yakin', 'yakni', 'yang']

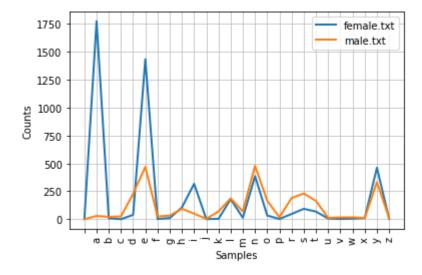
daftar nama dan gender yang disediakan oleh nltk

```
In [75]: names = nltk.corpus.names
```

```
In [76]: male_names = names.words('male.txt')
    female_names = names.words('female.txt')
    print([w for w in male_names if w in female_names])
```

['Abbey', 'Abbie', 'Abby', 'Addie', 'Adrian', 'Adrien', 'Ajay', 'Alexi, 'Alexi s', 'Alfie', 'Ali', 'Alix', 'Allie', 'Allyn', 'Andie', 'Andrea', 'Andy', 'Ange 'Angie', 'Ariel', 'Ashley', 'Aubrey', 'Augustine', 'Austin', 'Averil', 'Bar rie', 'Barry', 'Beau', 'Bennie', 'Benny', 'Bernie', 'Bert', 'Bertie', 'Bill', 'Billie', 'Billy', 'Blair', 'Blake', 'Bo', 'Bobbie', 'Bobby', 'Brandy', 'Bret t', 'Britt', 'Brook', 'Brooke', 'Brooks', 'Bryn', 'Cal', 'Cam', 'Cammy', 'Care y', 'Carlie', 'Carlin', 'Carmine', 'Carroll', 'Cary', 'Caryl', 'Casey', 'Cass', 'Cat', 'Cecil', 'Chad', 'Chris', 'Chrissy', 'Christian', 'Christie', 'Christy', 'Clair', 'Claire', 'Clare', 'Claude', 'Clem', 'Clemmie', 'Cody', 'Connie', 'Con stantiné', 'Corey', 'Corrié', 'Cory', 'Courtney', 'Cris', 'Daffý', 'Dale', 'Dal las', 'Dana', 'Dani', 'Daniel', 'Dannie', 'Danny', 'Darby', 'Darcy', 'Darryl', 'Daryl', 'Deane', 'Del', 'Dell', 'Demetris', 'Dennie', 'Denny', 'Devin', 'Devo n', 'Dion', 'Dionis', 'Dominique', 'Donnie', 'Donny', 'Dorian', 'Dory', 'Drew', 'Eddie', 'Eddy', 'Edie', 'Elisha', 'Emmy', 'Erin', 'Esme', 'Evelyn', 'Felice', 'Francis', 'Frank', 'Frankie', 'Franky', 'Fred', 'Freddie', 'Freddy', 'Gabriel', 'Gabriell', 'Gail', 'Gale', 'Gay', 'Gayle', 'Gene', 'George', 'Georg ia', 'Georgie', 'Geri', 'Germaine', 'Gerri', 'Gerry', 'Gill', 'Ginger', 'Glen', 'Glenn', 'Grace', 'Gretchen', 'Gus', 'Haleigh', 'Haley', 'Hannibal', 'Harley', 'Hazel', 'Heath', 'Henrie', 'Hillary', 'Hillary', 'Holly', 'Ike', 'Ikey', 'Ira', 'Isa', 'Isador', 'Isadore', 'Jackie', 'Jaime', 'Jamie', 'Jan', 'Jean', 'Jere', 'Jermaine', 'Jerrie', 'Jerry', 'Jess', 'Jesse', 'Jessie', 'Jo', 'Jodi', 'Jodi e', 'Jody', 'Joey', 'Jordan', 'Juanita', 'Jude', 'Judith', 'Judy', 'Julie', 'Ju stin', 'Karel', 'Kellen', 'Kelley', 'Kelly', 'Kelsey', 'Kerry', 'Kim', 'Kip', 'Kirby', 'Kit', 'Kris', 'Kyle', 'Lane', 'Lanny', 'Lauren', 'Laurie', 'Lee', 'Le igh', 'Leland', 'Lesley', 'Leslie', 'Lin', 'Lind', 'Lindsay', 'Lindsey', 'Lind y', 'Lonnie', 'Loren', 'Lorne', 'Lorrie', 'Lou', 'Luce', 'Lyn', 'Lynn', 'Maddi 'Maddy', 'Marietta', 'Marion', 'Marlo', 'Martie', 'Marty', 'Mattie', 'Matt y', 'Maurise', 'Maxie', 'Mead', 'Meade', 'Mel', 'Meredith', 'Merle', 'Me rrill', 'Merry', 'Meryl', 'Michal', 'Michel', 'Michele', 'Mickie', 'Micky', 'Mi llicent', 'Morgan', 'Morlee', 'Muffin', 'Nat', 'Nichole', 'Nickie', 'Nicky', 'N iki', 'Nikki', 'Noel', 'Ollie', 'Page', 'Paige', 'Pat', 'Patrice', 'Patsy', 'Pa ttie', 'Patty', 'Pen', 'Pennie', 'Penny', 'Perry', 'Phil', 'Pooh', 'Quentin', 'Quinn', 'Randi', 'Randie', 'Randy', 'Ray', 'Regan', 'Reggie', 'Rene', 'Rey', 'Ricki', 'Rickie', 'Ricky', 'Rikki', 'Robbie', 'Robin', 'Ronnie', 'Ronny', 'Ror y', 'Ruby', 'Sal', 'Sam', 'Sammy', 'Sandy', 'Sascha', 'Sasha', 'Saundra', 'Sayr e', 'Scotty', 'Sean', 'Shaine', 'Shane', 'Shannon', 'Shaun', 'Shawn', 'Shay', 'Shayne', 'Shea', 'Shelby', 'Shell', 'Shelley', 'Sibyl', 'Simone', 'Sonnie', 'S onny', 'Stacy', 'Sunny', 'Sydney', 'Tabbie', 'Tabby', 'Tallie', 'Tally', 'Tammi e', 'Tammy', 'Tate', 'Ted', 'Teddie', 'Teddy', 'Terri', 'Terry', 'Theo', 'Tim', 'Timmie', 'Timmy', 'Tobe', 'Tobie', 'Toby', 'Tommie', 'Tommy', 'Tony', 'Torey', 'Trace', 'Tracey', 'Tracie', 'Tracy', 'Val', 'Vale', 'Valentine', 'Van', 'Vin', 'Vinnie', 'Vinny', 'Virgie', 'Wallie', 'Wallis', 'Wally', 'Whitney', 'Willi', 'Willie', 'Willy', 'Winnie', 'Winny', 'Wynn']

code dibawah ini untuk melihat plot frequensi data dari nama laki-laki atau perempuan



# 4.2 A Pronouncing Dictionary

```
In [78]: entries = nltk.corpus.cmudict.entries()
```

untuk melihat panjang dari entries bisa menggunakan kode dibawah ini

```
In [79]: len(entries)
```

Out[79]: 133737

untuk melihat 15 data entries bisa menggunakan kode dibawah ini tetapi kita juga bisa melihat di range tertentu dengan cara entries[index\_awal:index\_akhir]

```
In [80]: for entry in entries[:15]:
              print(entry)
          ('a', ['AH0'])
          ('a.', ['EY1'])
          ('a', ['EY1'])
          ('a42128', ['EY1', 'F', 'A01', 'R', 'T', 'UW1', 'W', 'AH1', 'N', 'T', 'UW1', 'E
         Y1', 'T'])
         ('aaa', ['T', 'R', 'IH2', 'P', 'AH0', 'L', 'EY1'])
          ('aaberg', ['AA1', 'B', 'ER0', 'G'])
         ('aachen', ['AA1', 'K', 'AH0', 'N'])
          ('aachener', ['AA1', 'K', 'AH0', 'N', 'ER0'])
          ('aaker', ['AA1', 'K', 'ER0'])
          ('aalseth', ['AA1', 'L', 'S', 'EH0', 'TH'])
         ('aamodt', ['AA1', 'M', 'AH0', 'T'])
          ('aancor', ['AA1', 'N', 'K', 'A02', 'R'])
          ('aardema', ['AA0', 'R', 'D', 'EH1', 'M', 'AH0'])
          ('aardvark', ['AA1', 'R', 'D', 'V', 'AA2', 'R', 'K'])
          ('aaron', ['EH1', 'R', 'AH0', 'N'])
```

untuk melihat jumlah pron tertentu kita dapat menggunakan kode dibawah ini, dan juka kita dapat mengecek untuk yang berawalan huruf R dan berakhiran huruf S yang memiliki 4 pronon

```
In [81]: for word, pron in entries:
    if len(pron) == 4:
        ph1, ph2, ph3, ph4 = pron
        if ph1 == 'R' and ph4 == 'S':
            print(word, ph2, end=' ')
```

hritz IH1 raatz AA1 racks AE1 raetz IY1 raikes EY1 rakes EY1 rance AE1 rapes EY1 raps AE1 rate's EY1 rates EY1 rat's AE1 rats AE1 ratts AE1 ratz AE1 rax AE1 reaps IY1 reefs IY1 reeks IY1 reetz IY1 reich's AY1 reicks AY1 reits AY1 reitz AY1 rep's EH1 reps EH1 retz EH1 rewis UW1 rex EH1 reyes EY1 rick's IH1 ricks IH1 rietz IY1 riffs IH1 right's AY1 rights AY1 rights' AY1 rinse IH1 rios IY1 rips IH1 rite's AY1 rites AY1 ritt's IH1 ritts IH1 ritz IH1 rix IH1 rock's AA1 rocks AA1 roofs UW1 rooks UH1 roots UW1 ropes OW1 rops AA1 roth's AA1 roths AO1 rots AA1 rotz AA1 rough's AH1 routes UW1 routes AW1 routes UH1 rox AA1 rucks AH1 ruetz UW1 rusts AH1 ruth's UW1 ruts AH1 rutz AH1 rux AH1 wraps AE1 wreaks IY1 wreaths IY1 wrecks EH1 wright's AY1 wrights AY1 writes AY1 writs IH1

untuk menampilkan syllable tertentu bisa menggunakan kode dibawah ini

```
syllable = ['N', 'IHO', 'K', 'S']
          [word for word, pron in entries if pron[-4:] == syllable]
Out[82]: ["atlantic's",
           'audiotronics',
           'avionics',
           'beatniks',
           'calisthenics',
           'centronics',
           'chamonix',
           'chetniks',
           "clinic's",
           'clinics',
           'conics',
           'conics',
           'cryogenics',
           'cynics',
           'diasonics',
           "dominic's",
           'ebonics',
           'electronics',
           "electronics'",
           "endotronics'",
           'endotronics',
           'enix',
           'environics',
           'ethnics',
           'eugenics',
           'fibronics',
           'flextronics',
           'harmonics',
           'hispanics',
           'histrionics',
           'identics',
           'ionics',
           'kibbutzniks',
           'lasersonics',
           'lumonics',
           'mannix',
           'mechanics',
           "mechanics'",
           'microelectronics',
           'minix',
           'minnix',
           'mnemonics',
           'mnemonics',
           'molonicks',
           'mullenix',
           'mullenix',
           'mullinix',
           'mulnix',
           "munich's",
           'nucleonics',
           'onyx',
           'organics',
           "panic's",
```

'panics',

```
'penix',
'pennix',
'personics',
'phenix',
"philharmonic's",
'phoenix',
'phonics',
'photronics',
'pinnix',
'plantronics',
'pyrotechnics',
'refuseniks',
"resnick's",
'respironics',
'sconnix',
'siliconix',
'skolniks',
'sonics',
'sputniks',
'technics',
'tectonics',
'tektronix',
'telectronics',
'telephonics',
'tonics',
'unix',
"vinick's",
"vinnick's",
'vitronics']
```

untuk menampilkan pronon tertentu dan berakhiran huruf tertentu bisa menggunakan kode dibawah ini, seperti mengecek yang pronon S dan berakhiran huruf t

```
In [83]: [w for w, pron in entries if pron[-1] == 'S' and w[-1] == 't']
Out[83]: ['cataract', 'corexit', 'last', 'leubert', 'most', 'next']
```

untuk mengurutkan sebuah data kita bisa menggunakan sorted seperti pada kode dibawah ini

```
In [84]: sorted(set(w[:2] for w, pron in entries if pron[0] == 'N' and w[0] != 'n'))
Out[84]: ['gn', 'kn', 'mn', 'pn']
In [85]: def stress(pron):
    return [char for phone in pron for char in phone if char.isdigit()]
In [86]: data = [w for w, pron in entries if stress(pron) == ['0', '1', '0', '2', '0']]
    print(data[:10])
    ['abbreviated', 'abbreviating', 'accelerated', 'accelerating', 'accelerator', 'accelerators', 'accentuated', 'accentuating', 'accommodated']
```

untuk mengecek pronon tertentu dan kata yang menggunakan pronon tersebut bisa menggunakan

kode dibawah ini

```
In [87]: p3 = [(pron[0]+'-'+pron[2], word)]
               for (word, pron) in entries
               if pron[0] == 'P' and len(pron) == 3]
In [88]:
         cfd = nltk.ConditionalFreqDist(p3)
In [89]: | for template in sorted(cfd.conditions()):
             if len(cfd[template]) > 10:
                 words = sorted(cfd[template])
                 wordstring = ' '.join(words)
                 print(template, wordstring[:70] + "...")
         P-CH patch pautsch peach perch petsch petsche piche piech pietsch pitch pit...
         P-K pac pack paek paik pak pake paque peak peake pech peck peek perc perk ...
         P-L pahl pail paille pal pale pall paul paule paull peal pearl pearl...
         P-N paign pain paine pan pane pawn payne peine pen penh penn pin pine pinn...
         P-P paap paape pap pape papp paup peep pep pip pipe pipp poop pop pope pop...
         P-R paar pair par pare parr pear peer pier poor poore por pore porr pour...
         P-S pace pass pasts peace pearse pease perce pers perse pesce piece piss p...
         P-T pait pat pate patt peart peat peet peete pert pet pete piet piett...
         P-UW1 peru peugh pew plew plue prew pru prue prugh pshew pugh...
```

## 4.3 Comparative Wordlists

untuk melihat komparatif wordlist kita bisa menggunakan kode dibawah ini, dimana ini disediakan oleh NLTK

P-Z p's p.'s p.s pais paiz pao's pas pause paws pays paz peas pease pei's ...

```
In [90]: from nltk.corpus import swadesh
```

terdapat beberapa bahasa yang disediakan seperti english spanyol dll, bisa di lihat dari pilihan yang tersedia

```
In [91]: print(swadesh.fileids())
        ['be', 'bg', 'bs', 'ca', 'cs', 'cu', 'de', 'en', 'es', 'fr', 'hr', 'it', 'la', 'mk', 'nl', 'pl', 'ro', 'ru', 'sk', 'sl', 'sr', 'sw', 'uk']
```

berikut beberapa contoh dari kata yg tersedia di bahasa spanyol dan inggris

In [92]: print("Spanyol ",swadesh.words('es'))

Spanyol ['yo', 'tú, usted', 'él', 'nosotros', 'vosotros, ustedes', 'ellos, ell as', 'este', 'ese, aquel', 'aquí, acá', 'ahí, allí, allá', 'quien', 'que', 'don de', 'cuando', 'como', 'no', 'todo', 'muchos', 'algunos, unos', 'poco', 'otro', 'uno', 'dos', 'tres', 'cuatro', 'cinco', 'grande', 'largo', 'ancho', 'gordo', 'pesado', 'pequeño', 'corto', 'estrecho, angosto', 'delgado, flaco', 'mujer', 'hombre', 'hombre', 'niño', 'esposa, mujer', 'esposo, marido', 'madre', 'padr e', 'animal', 'pez, pescado', 'ave, pájaro', 'perro', 'piojo', 'serpiente, cule bra', 'gusano', 'árbol', 'bosque', 'palo', 'fruta', 'semilla', 'hoja', 'raíz', 'corteza', 'flor', 'hierba, pasto', 'cuerda', 'piel', 'carne', 'sangre', 'hues o', 'grasa', 'huevo', 'cuerno', 'cola', 'pluma', 'cabello, pelo', 'cabeza', 'or eja', 'ojo', 'nariz', 'boca', 'diente', 'lengua', 'uña', 'pie', 'pierna', 'rodi lla', 'mano', 'ala', 'barriga, vientre, panza', 'entrañas, tripas', 'cuello', 'espalda', 'pecho, seno', 'corazón', 'hígado', 'beber, tomar', 'comer', 'morde r', 'chupar', 'escupir', 'vomitar', 'soplar', 'respirar', 'reír', 'ver', 'oír', 'saber', 'pensar', 'oler', 'temer', 'dormir', 'vivir', 'morir', 'matar', 'pelea r', 'cazar', 'golpear', 'cortar', 'partir', 'apuñalar', 'arañar, rascar', 'cava r', 'nadar', 'volar', 'caminar', 'venir', 'echarse, acostarse, tenderse', 'sent arse', 'estar de pie', 'voltear', 'caer', 'dar', 'sostener', 'apretar', 'frota r', 'lavar', 'limpiar', 'tirar', 'empujar', 'tirar', 'atar', 'coser', 'contar', 'decir', 'cantar', 'jugar', 'flotar', 'fluir', 'helar', 'hincharse', 'sol', 'lu na', 'estrella', 'agua', 'lluvia', 'río', 'lago', 'mar', 'sal', 'piedra', 'aren a', 'polvo', 'tierra', 'nube', 'niebla', 'cielo', 'viento', 'nieve', 'hielo', 'humo', 'fuego', 'cenizas', 'quemar', 'camino', 'montaña', 'rojo', 'verde', 'am arillo', 'blanco', 'negro', 'noche', 'día', 'año', 'cálido, tibio', 'frío', 'll eno', 'nuevo', 'viejo', 'bueno', 'malo', 'podrido', 'sucio', 'recto', 'redond o', 'afilado', 'desafilado', 'suave, liso', 'mojado', 'seco', 'correcto', 'cerc a', 'lejos', 'derecha', 'izquierda', 'a, en, ante', 'en', 'con', 'y', 'si', 'po rque', 'nombre']

## In [93]: print("English ",swadesh.words('en'))

English ['I', 'you (singular), thou', 'he', 'we', 'you (plural)', 'they', 'thi s', 'that', 'here', 'there', 'who', 'what', 'where', 'when', 'how', 'not', 'al l', 'many', 'some', 'few', 'other', 'one', 'two', 'three', 'four', 'five', 'big', 'long', 'wide', 'thick', 'heavy', 'small', 'short', 'narrow', 'thin', 'woma n', 'man (adult male)', 'man (human being)', 'child', 'wife', 'husband', 'mothe r', 'father', 'animal', 'fish', 'bird', 'dog', 'louse', 'snake', 'worm', 'tre e', 'forest', 'stick', 'fruit', 'seed', 'leaf', 'root', 'bark (from tree)', 'fl ower', 'grass', 'rope', 'skin', 'meat', 'blood', 'bone', 'fat (noun)', 'egg', 'horn', 'tail', 'feather', 'hair', 'head', 'ear', 'eye', 'nose', 'mouth', 'tooth', 'tongue', 'fingernail', 'foot', 'leg', 'knee', 'hand', 'wing', 'belly', 'gu ts', 'neck', 'back', 'breast', 'heart', 'liver', 'drink', 'eat', 'bite', 'suc k', 'spit', 'vomit', 'blow', 'breathe', 'laugh', 'see', 'hear', 'know (a fac t)', 'think', 'smell', 'fear', 'sleep', 'live', 'die', 'kill', 'fight', 'hunt', 'hit', 'cut', 'split', 'stab', 'scratch', 'dig', 'swim', 'fly (verb)', 'walk', 'come', 'lie', 'sit', 'stand', 'turn', 'fall', 'give', 'hold', 'squeeze', 'ru b', 'wash', 'wipe', 'pull', 'push', 'throw', 'tie', 'sew', 'count', 'say', 'sin g', 'play', 'float', 'flow', 'freeze', 'swell', 'sun', 'moon', 'star', 'water', 'rain', 'river', 'lake', 'sea', 'salt', 'stone', 'sand', 'dust', 'earth', 'clou d', 'fog', 'sky', 'wind', 'snow', 'ice', 'smoke', 'fire', 'ashes', 'burn', 'roa
d', 'mountain', 'red', 'green', 'yellow', 'white', 'black', 'night', 'day', 'ye ar', 'warm', 'cold', 'full', 'new', 'old', 'good', 'bad', 'rotten', 'dirty', 's traight', 'round', 'sharp', 'dull', 'smooth', 'wet', 'dry', 'correct', 'near', 'far', 'right', 'left', 'at', 'in', 'with', 'and', 'if', 'because', 'name']

perbandingan bahasa inggris dan espanyol

```
In [94]: fr2en = swadesh.entries(['en', 'es'])
          fr2en[:30]
Out[94]: [('I', 'yo'),
           ('you (singular), thou', 'tú, usted'),
           ('he', 'él'),
           ('we', 'nosotros'),
           ('you (plural)', 'vosotros, ustedes'),
           ('they', 'ellos, ellas'),
           ('this', 'este'),
           ('that', 'ese, aquel'),
           ('here', 'aquí, acá'),
           ('there', 'ahí, allí, allá'),
           ('who', 'quien'), ('what', 'que'),
           ('where', 'donde'),
           ('when', 'cuando'),
           ('how', 'como'),
           ('not', 'no'),
           ('all', 'todo'),
           ('many', 'muchos'),
           ('some', 'algunos, unos'),
           ('few', 'poco'),
           ('other', 'otro'),
           ('one', 'uno'),
           ('two', 'dos'),
           ('three', 'tres'),
           ('four', 'cuatro'),
           ('five', 'cinco'),
           ('big', 'grande'),
           ('long', 'largo'),
           ('wide', 'ancho'),
           ('thick', 'gordo')]
```

dengan memanfaatkan list tersebut kita bisa menggunakan nya sebagai sebuah kamus dengan cara penggunaan seperti kode dibawah ini

kita juga bisa menggunakan translate antar bahasa dengan menggunakan kode bahasa yang tersedia di atas dan dengan kode seperti diatas sesuai dengan yang kita butuhkan

```
In [95]: translate = dict(fr2en)
    translate['how']
Out[95]: 'como'
```

Contoh kita akan membuat translate inggris ke german maka bisa menggunakan kode ini

```
In [96]: en2de = swadesh.entries(['en', 'de'])
In [97]: translate.update(dict(en2de))
```

```
In [98]: translate['what']
Out[98]: 'was'
```

#### 4.4 Shoebox and Toolbox Lexicons

```
In [99]: from nltk.corpus import toolbox
In [100]: toolbox.entries('rotokas.dic')[:2]
Out[100]: [('kaa',
             [('ps', 'V'),
              ('pt', 'A'),
              ('ge', 'gag'),
              ('tkp', 'nek i pas'),
              ('dcsv', 'true'),
              ('vx', '1'),
              ('sc', '???'),
('dt', '29/0ct/2005'),
              ('ex', 'Apoka ira kaaroi aioa-ia reoreopaoro.'),
              ('xp', 'Kaikai i pas long nek bilong Apoka bikos em i kaikai na toktok.'),
              ('xe', 'Apoka is gagging from food while talking.')]),
            ('kaa',
             [('ps', 'V'),
              ('pt', 'B'),
              ('ge', 'strangle'),
('tkp', 'pasim nek'),
('arg', 'O'),
              ('vx', '2'),
              ('dt', '07/Oct/2006'),
              ('ex', 'Rera rauroro rera kaarevoi.'),
              ('xp', 'Em i holim pas em na nekim em.'),
              ('xe', 'He is holding him and strangling him.'),
              ('ex', 'Iroiro-ia oirato okoearo kaaivoi uvare rirovira kaureoparoveira.'),
              ('xp', 'Ol i pasim nek bilong man long rop bikos em i save bikhet tumas.'),
              ('xe',
               "They strangled the man's neck with rope because he was very stubborn and a
           rrogant."),
              ('ex',
                'Oirato okoearo kaaivoi iroiro-ia. Uva viapau uvuiparoi ra vovouparo uva ko
           piiroi.'),
              ('xp',
               'Ol i pasim nek bilong man long rop. Olsem na em i no pulim win olsem na em
           i dai.'),
               "They strangled the man's neck with a rope. And he couldn't breathe and he
           died.")])]
```

#### 5 WordNet

## 5.1 Senses and Synonyms

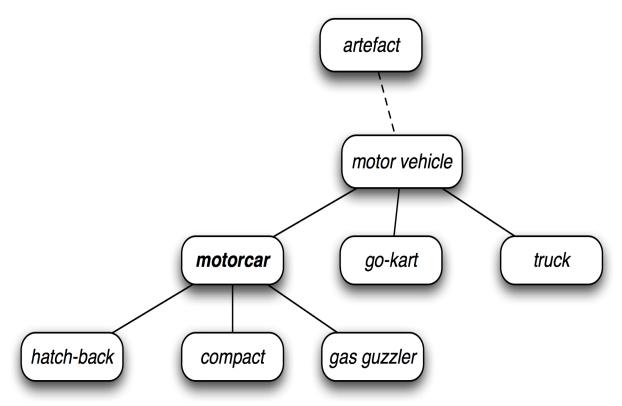
nltk menyediakan sebuah data synonyms untuk mengetahui sebuah makna yang mirip, untuk menggunakannya kita bisa menggunakan kode seperti dibawah ini

```
In [101]: from nltk.corpus import wordnet as wn
```

untuk mengecek kesamaan makna atau synonym bisa menggunakan kode seperti dibawah ini

```
print(wn.synsets('motorcar'))
In [102]:
          print(wn.synset('car.n.01').lemma names())
          [Synset('car.n.01')]
          ['car', 'auto', 'automobile', 'machine', 'motorcar']
In [103]:
          print(wn.synsets("cake"))
          print(wn.synset('cake.n.01').lemma_names())
          print(wn.synset('patty.n.01').lemma names())
          print(wn.synset('cake.n.03').lemma_names())
          print(wn.synset('coat.v.03').lemma_names())
          [Synset('cake.n.01'), Synset('patty.n.01'), Synset('cake.n.03'), Synset('coat.
          v.03')]
          ['cake', 'bar']
          ['patty', 'cake']
          ['cake']
          ['coat', 'cake']
In [104]:
          print(wn.synsets("drink"))
          print(wn.synset('drink.n.01').lemma names())
          print(wn.synset('beverage.n.01').lemma_names())
          print(wn.synset('drink.n.04').lemma names())
          print(wn.synset('swallow.n.02').lemma_names())
          print(wn.synset('drink.v.01').lemma names())
          print(wn.synset('drink.v.02').lemma names())
          print(wn.synset('toast.v.02').lemma names())
          print(wn.synset('drink_in.v.01').lemma_names())
          print(wn.synset('drink.v.05').lemma names())
          [Synset('drink.n.01'), Synset('drink.n.02'), Synset('beverage.n.01'), Synset('d
          rink.n.04'), Synset('swallow.n.02'), Synset('drink.v.01'), Synset('drink.v.0
          2'), Synset('toast.v.02'), Synset('drink_in.v.01'), Synset('drink.v.05')]
          ['drink']
          ['beverage', 'drink', 'drinkable', 'potable']
          ['drink']
          ['swallow', 'drink', 'deglutition']
          ['drink', 'imbibe']
          ['drink', 'booze', 'fuddle']
          ['toast', 'drink', 'pledge', 'salute', 'wassail']
          ['drink_in', 'drink']
          ['drink', 'tope']
```

# **5.2 The WordNet Hierarchy**



```
In [105]:
           drink = wn.synset('drink.v.01')
           drink_type = drink.hyponyms()
           drink_type[0]
Out[105]: Synset('drain_the_cup.v.01')
In [106]:
           sorted(lemma.name() for synset in drink_type for lemma in synset.lemmas())
Out[106]: ['belt_down',
            'bolt_down',
            'down',
            'drain_the_cup',
            'drink_down',
            'drink_up',
            'guggle',
            'gulp',
            'gurgle',
            'guzzle',
            'kill',
            'lap',
            'lap_up',
            'lick',
            'pop',
            'pour_down',
            'quaff',
            'sip',
            'suck',
            'swig',
            'swill',
            'swill_down',
            'toss_off']
```

```
In [107]: drink.hypernyms()
Out[107]: [Synset('consume.v.02')]
In [108]: paths = drink.hypernym_paths()
          len(paths)
Out[108]: 1
In [109]: [synset.name() for synset in paths[0]]
Out[109]: ['consume.v.02', 'drink.v.01']
           drink.root hypernyms()
In [110]:
Out[110]: [Synset('consume.v.02')]
          5.3 More Lexical Relations
In [111]: wn.synset('tree.n.01').part meronyms()
Out[111]: [Synset('burl.n.02'),
           Synset('crown.n.07'),
           Synset('limb.n.02'),
           Synset('stump.n.01'),
           Synset('trunk.n.01')]
In [112]:
           wn.synset('tree.n.01').substance_meronyms()
Out[112]: [Synset('heartwood.n.01'), Synset('sapwood.n.01')]
In [113]: wn.synset('tree.n.01').member holonyms()
Out[113]: [Synset('forest.n.01')]
In [114]: | for synset in wn.synsets('mint', wn.NOUN):
              print(synset.name() + ':', synset.definition())
          batch.n.02: (often followed by `of') a large number or amount or extent
          mint.n.02: any north temperate plant of the genus Mentha with aromatic leaves a
          nd small mauve flowers
          mint.n.03: any member of the mint family of plants
          mint.n.04: the leaves of a mint plant used fresh or candied
          mint.n.05: a candy that is flavored with a mint oil
          mint.n.06: a plant where money is coined by authority of the government
In [115]: wn.synset('mint.n.04').part_holonyms()
Out[115]: [Synset('mint.n.02')]
```

```
In [116]: wn.synset('mint.n.04').substance holonyms()
Out[116]: [Synset('mint.n.05')]
In [117]: wn.synset('walk.v.01').entailments()
Out[117]: [Synset('step.v.01')]
In [118]: | wn.synset('eat.v.01').entailments()
Out[118]: [Synset('chew.v.01'), Synset('swallow.v.01')]
In [119]: | wn.synset('tease.v.03').entailments()
Out[119]: [Synset('arouse.v.07'), Synset('disappoint.v.01')]
In [120]: wn.lemma('supply.n.02.supply').antonyms()
Out[120]: [Lemma('demand.n.02.demand')]
In [121]: | wn.lemma('rush.v.01.rush').antonyms()
Out[121]: [Lemma('linger.v.04.linger')]
In [122]: wn.lemma('horizontal.a.01.horizontal').antonyms()
Out[122]: [Lemma('vertical.a.01.vertical'), Lemma('inclined.a.02.inclined')]
In [123]: | wn.lemma('staccato.r.01.staccato').antonyms()
Out[123]: [Lemma('legato.r.01.legato')]
          5.4 Semantic Similarity
In [124]:
          right = wn.synset('right_whale.n.01')
          orca = wn.synset('orca.n.01')
          minke = wn.synset('minke whale.n.01')
          tortoise = wn.synset('tortoise.n.01')
          novel = wn.synset('novel.n.01')
In [125]:
          print("minke" , right.lowest_common_hypernyms(minke))
          print("orca" , right.lowest_common_hypernyms(orca))
          print("tortoise" , right.lowest_common_hypernyms(tortoise))
          print("novel" , right.lowest_common_hypernyms(novel))
```

minke [Synset('baleen whale.n.01')]

tortoise [Synset('vertebrate.n.01')]

orca [Synset('whale.n.02')]

novel [Synset('entity.n.01')]

```
In [126]:
          print("right" , orca.lowest_common_hypernyms(right))
          print("minke" , orca.lowest_common_hypernyms(minke))
          print("tortoise" , orca.lowest_common_hypernyms(tortoise))
          print("novel" , orca.lowest common hypernyms(novel))
          right [Synset('whale.n.02')]
          minke [Synset('whale.n.02')]
          tortoise [Synset('vertebrate.n.01')]
          novel [Synset('entity.n.01')]
In [127]: right.lowest_common_hypernyms(tortoise)
Out[127]: [Synset('vertebrate.n.01')]
In [128]: | right.lowest_common_hypernyms(novel)
Out[128]: [Synset('entity.n.01')]
In [129]: wn.synset('baleen whale.n.01').min depth()
Out[129]: 14
In [130]: | wn.synset('whale.n.02').min_depth()
Out[130]: 13
In [131]: wn.synset('vertebrate.n.01').min depth()
Out[131]: 8
In [132]: wn.synset('entity.n.01').min depth()
Out[132]: 0
In [133]: right.path similarity(minke)
Out[133]: 0.25
In [134]: right.path_similarity(orca)
Out[134]: 0.1666666666666666
In [135]: | right.path_similarity(tortoise)
Out[135]: 0.07692307692307693
In [136]: | right.path_similarity(novel)
Out[136]: 0.043478260869565216
```

# 6 Summary

 Korpus teks adalah kumpulan teks yang besar dan terstruktur. NLTK hadir dengan banyak korpora, mis., Brown Corpus, nltk.corpus.brown.

- Beberapa korpora teks dikategorikan, misalnya, berdasarkan genre atau topik; terkadang kategori korpus saling tumpang tindih.
- Distribusi frekuensi bersyarat adalah kumpulan distribusi frekuensi, masing-masing untuk kondisi yang berbeda. Mereka dapat digunakan untuk menghitung frekuensi kata, diberikan konteks atau genre.
- Program python yang panjangnya lebih dari beberapa baris harus dimasukkan menggunakan editor teks, disimpan ke file dengan ekstensi .py, dan diakses menggunakan pernyataan impor.
- Fungsi Python memungkinkan Anda untuk mengaitkan nama dengan blok kode tertentu, dan menggunakan kembali kode itu sesering yang diperlukan.
- Beberapa fungsi, yang dikenal sebagai "metode", dikaitkan dengan objek dan kami memberikan nama objek diikuti dengan periode yang diikuti oleh fungsi, seperti ini: x.funct (y), mis., Word.isalpha ().
- Untuk mencari tahu tentang beberapa variabel v, ketik help (v) dalam interpreter interaktif Python untuk membaca entri bantuan untuk objek semacam ini.
- WordNet adalah kamus bahasa Inggris yang berorientasi semantik, yang terdiri dari set sinonim atau sinkronisasi dan disusun dalam suatu jaringan.
- Beberapa fungsi tidak tersedia secara default, tetapi harus diakses menggunakan pernyataan impor Python.